

Clase del M3

Sitio: [Campus - Sadosky Capacitaciones](#)
Curso: Introducción a la administración de clústeres HPC_V1
Libro: Clase del M3

Imprimido por: Pablo Carrai
Día: martes, 16 de junio de 2026, 14:44

Tabla de contenidos

Introducción

- 3.1 La necesidad del almacenamiento compartido
 - 3.2 La solución estándar: NFS y NAS
 - 3.3 Sistemas de archivos paralelos
 - 3.4 Recomendaciones y buenas prácticas
- Cierre

Introducción

Este módulo aborda un problema crucial: visibilidad y acceso a datos en clústeres de HPC. Veremos las limitaciones del almacenamiento centralizado tradicional y abordaremos una solución de alto rendimiento: los Sistemas de Archivos Paralelos. Finalmente, compartiremos algunas prácticas recomendadas como la utilización de NFS (*Network File System*, 'Sistema de archivos de red') para archivos pequeños y la configuración y el almacenamiento paralelo para todas las cargas de trabajo intensivas y *datasets* grandes.



Nuestro objetivo en esta oportunidad es entender las limitaciones de los sistemas de archivos tradicionales en entornos HPC y comprender la arquitectura y ventajas de los sistemas de archivos paralelos.

3.1 La necesidad del almacenamiento compartido

Un clúster, al estar compuesto por múltiples nodos (servidores) que trabajan conjuntamente para ofrecer un servicio o ejecutar una aplicación, requiere que todos los miembros tengan acceso a un mismo conjunto de datos de manera simultánea y coherente.


El desafío del acceso concurrente: el problema del *home*

El problema fundamental de la visibilidad de datos en un entorno HPC es el almacenamiento local.

Para ilustrar la necesidad de un sistema de archivos compartido y distribuido, consideremos el flujo de trabajo típico de un usuario en un clúster HPC:

El problema del home

Flujo de trabajo típico de un usuario en un clúster HPC:



El problema crítico del almacenamiento local

Aquí es donde surge la limitación crítica si el clúster utiliza un esquema de almacenamiento estrictamente local (es decir, cada nodo tiene su propio disco duro independiente y aislado):

- El archivo ejecutable **a.out** fue creado en el disco duro local del nodo01.
- Cuando el **nodo50** recibe la instrucción del sistema de colas para ejecutar la aplicación, lo primero que intenta hacer es localizar y cargar el archivo **a.out**.
- El resultado: El **nodo50** no puede "ver" el archivo **a.out** porque este reside exclusivamente en el sistema de archivos del **nodo01**. El intento de ejecución fallará con un error de "archivo no encontrado" o similar.



Esta situación dificulta la utilización eficiente de un clúster de HPC. El usuario se vería forzado a transferir manualmente los archivos de programa y datos a cada nodo antes de la ejecución o, en el peor de los casos, a utilizar exclusivamente el nodo donde realizó la compilación.

Por esta razón crucial, los clústeres HPC necesitan incorporar un sistema de archivos que garantice la disponibilidad en todos los nodos.

Requisitos esenciales de un sistema de archivos distribuido

Los sistemas de archivos distribuidos deben cumplir con las siguientes propiedades clave:


- **Espacio de nombres único (*single namespace*):** la ruta `/home/usuario` debe ofrecer el mismo contenido y estructura, independientemente del nodo de cómputo que se utilice para acceder a ella.
- **Consistencia inmediata:** una vez que se realiza una escritura de datos, la información debe estar disponible para lectura por todos los nodos de manera instantánea.
- **Tolerancia a fallos (movilidad de datos):** los datos almacenados deben persistir y estar accesibles incluso si un nodo de cómputo específico deja de funcionar (o "cae").

3.2 La solución estándar: NFS y NAS

El protocolo NFS

Network File System (NFS) es el protocolo de red por excelencia y el estándar de facto en sistemas operativos basados en Unix y Linux para permitir la compartición transparente de archivos y directorios a través de una red. Su objetivo principal es hacer que un sistema de archivos remoto parezca ser un sistema de archivos local para el usuario y las aplicaciones. Así facilita la centralización de datos y la gestión de recursos en entornos distribuidos.

El protocolo NFS opera bajo un modelo estricto de cliente-servidor.



Modelo operativo cliente-servidor

Lado del servidor (exportación): un sistema (el servidor NFS) configura y pone a disposición de la red uno o más directorios específicos. Este proceso se denomina *exportar el directorio*. Al exportar, el servidor define qué clientes tienen permiso para acceder a ese recurso y con qué nivel de privilegios (solo lectura, lectura/escritura, etc.).

Lado del cliente (montaje): otros sistemas (los clientes NFS) solicitan acceso a esos directorios compartidos. Este proceso se conoce como *montar el directorio remoto* en un punto de montaje local. Una vez montado, el sistema operativo cliente utiliza el protocolo NFS para gestionar las operaciones de entrada/salida (I/O) hacia el servidor, haciendo que el acceso sea indistinguible del acceso a un disco local desde la perspectiva del usuario.

A lo largo de su historia, NFS ha evolucionado para abordar problemas de rendimiento, seguridad y funcionalidad:

NFSv3 (*Network File System version 3*)

Esta versión se caracteriza por ser principalmente sin estado (*stateless*). Esto significa que cada solicitud del cliente al servidor es independiente y contiene toda la información necesaria para completarla. Aunque es más

simple y robusta ante fallos de servidor (la recuperación es más sencilla), puede tener limitaciones en el manejo eficiente de bloqueos de archivos (*locks*) y requiere protocolos auxiliares para mantener el estado.

NFSv4 (*Network File System version 4*)

Implica una reescritura significativa. Su principal característica es ser con estado (*stateful*). El estado se mantiene entre el cliente y el servidor, lo que permite un manejo mucho mejor y más confiable de los bloqueos de archivos (*locks*) persistentes. Además, NFSv4 incorpora importantes mejoras de seguridad al incluir soporte nativo para Kerberos, permitiendo una autenticación robusta y cifrado de datos. Esta versión también unifica operaciones y está diseñada para funcionar mejor a través de *firewalls*.

Veamos cuáles son las ventajas operacionales de NFS:

- > **Fácil de configurar e integrar**
- > **Integración a nivel de kernel**
- > **Transparencia para el usuario y las aplicaciones**

El concepto de NAS



El concepto de NAS (*Network Attached Storage*) representa una categoría fundamental en la infraestructura de almacenamiento moderna, ofreciendo una solución especializada y eficiente para compartir archivos a través de una red.

Es crucial distinguir entre el protocolo y el dispositivo:



Protocolos (NFS): son los lenguajes o conjuntos de reglas que permiten a los clientes (servidores, estaciones de trabajo) solicitar y recibir archivos a través de la red.

NAS: es un dispositivo dedicado (hardware) para el almacenamiento a nivel de archivo (*File-Level Storage*) que está específicamente optimizada para implementar y servir archivos utilizando protocolos como NFS.

Un NAS se puede describir típicamente como una "caja negra" optimizada para servir archivos. Esto implica varias características clave:

Limitaciones de la solución estándar

¿Por qué no usamos un NAS gigante para todo?

Limitación por ancho de banda del servidor

El ancho de banda del servidor puede ser un cuello de botella (*bottleneck*) crítico. Si 100 nodos solicitan datos a una tasa de 1 GB/s cada uno, se genera una demanda agregada de 100 GB/s. Si el servidor NFS solo dispone de una tarjeta de red con una capacidad de 10 GB/s, se producirá un atasco masivo e ineficiencia severa en el acceso a los datos.


Input/output por segundo (IOPS) y latencia

El disco duro (o arreglo RAID) del servidor tiene un límite físico de cuántas operaciones por segundo puede manejar.

Metadata

Las operaciones como `ls -l` en un directorio con millones de archivos pueden "matar" a un servidor NFS. Esto ocurre porque el servidor debe buscar uno por uno a los nodos (estructura de datos que almacena información sobre un archivo del sistema de archivos uno por uno).

El protocolo pNFS (Parallel NFS), un estándar IETF, surgió como un esfuerzo importante para permitir el acceso paralelo a datos a través de una infraestructura NFS existente, utilizando un mecanismo de *bypass* para que los clientes accedan directamente al almacenamiento. La última actualización de NFS, v4.1, incorpora una especificación para NFS paralelo (pNFS). El diseño intenta eliminar el cuello de botella asociado al uso de un solo servidor de archivos.




Organización conceptual de pNFS. Fuente: *Linux tutorials and tips* (s/fecha). En *nixCraft*: [https://\[https://www.cyberciti.biz/tips/linux-unix-parallel-nfs.html\]](https://www.cyberciti.biz/tips/linux-unix-parallel-nfs.html)

3.3 Sistemas de archivos paralelos

Cambio de paradigma: divide y vencerás

A diferencia de NFS, donde el archivo reside completamente en un único servidor de almacenamiento, lo que puede convertirse en un cuello de botella en términos de rendimiento y escalabilidad, en un sistema de archivos paralelo la gestión y el almacenamiento de los datos se abordan de manera fundamentalmente distinta.

En estos sistemas, el archivo se "despedaza" o se divide en múltiples segmentos (a menudo llamados "trozos" o "bloques") mediante una técnica conocida como *striping* ('división en bandas'). Estos segmentos se distribuyen y almacenan de forma concurrente a través de múltiples servidores de almacenamiento (o nodos de disco) interconectados.



Esta arquitectura distribuida ofrece varias ventajas cruciales:

1. **Paralelismo en acceso y transferencia de datos:** múltiples nodos acceden y transfieren datos simultáneamente, lo que incrementa el ancho de banda agregado y reduce la latencia, crucial para aplicaciones HPC con grandes volúmenes de datos.
2. **Tolerancia a fallos y redundancia:** la distribución de datos y los mecanismos de redundancia (replicación o *erasure coding*) aseguran la disponibilidad e integridad, evitando la pérdida total por fallo de un único servidor.
3. **Escalabilidad:** la capacidad y el rendimiento crecen linealmente al añadir más servidores de almacenamiento.

Por lo tanto, mientras que NFS es una solución de compartición de archivos sencilla y centralizada, un sistema paralelo es una arquitectura compleja y distribuida diseñada para maximizar el rendimiento de entrada/salida (I/O) y la capacidad para manejar cargas de trabajo intensivas en datos.


Separación de datos y metadatos

Un principio fundamental en los sistemas de archivos de alto rendimiento (como Lustre o GPFS) es la estricta separación de los datos y la información que los describe. Esto permite una escalabilidad masiva y optimiza el acceso.



MDS (*Metadata Server* o servidor de metadatos)

Actúa como el directorio central y la autoridad de gestión de todo el sistema. Su única responsabilidad es manejar la información descriptiva de los archivos (metadatos).



El MDS almacena:

- Propiedad y permisos: quién es el propietario del archivo y qué usuarios pueden leer, escribir o ejecutar (ACL).
- Nombres y jerarquía: la estructura de directorios y los nombres de los archivos.
- Mapa de ubicación: almacena la tabla que indica en qué servidores de datos y dónde están guardados los diferentes bloques o *chunks* de un archivo. Esto es crucial.
- Rol en la operación: cuando un cliente quiere acceder a un archivo, primero consulta al MDS. El MDS no entrega los datos, solo le indica al cliente el "mapa" para ir a buscar los datos directamente a los servidores de almacenamiento. Es el punto de control centralizado.



OSS/OST (*Object Storage Server/Target* o servidor/destino de almacenamiento de objetos)

Son las unidades de almacenamiento masivo. Guardan y sirven los contenidos binarios y los bloques de datos reales del usuario.

•


La información que almacenan los OSS/OST son los bloques o *chunks* del archivo en sí. A diferencia de un sistema de archivos tradicional, no manejan la jerarquía de directorios; solo guardan la porción del archivo que les corresponde como un "objeto" sin estructura interna visible.

Su gran ventaja es la escalabilidad. Se puede añadir una cantidad potencialmente ilimitada de OST para aumentar la capacidad de almacenamiento y, más importante aún, el rendimiento de entrada/salida (I/O).



Striping: distribución de datos que multiplica el ancho de banda

El *striping* (o seccionamiento) es la técnica clave que permite a estos sistemas de archivos alcanzar velocidades de transferencia que superan con creces las de cualquier disco o servidor individual.



Cuando se escribe un archivo grande, en lugar de guardarlo completo en un solo servidor de datos (OST), el sistema lo divide en segmentos de tamaño fijo llamados stripes o "trozos". Estos trozos son escritos de forma paralela en múltiples OST diferentes.

Ejemplo práctico

Imaginemos un archivo de 10 GB. El sistema podría configurarse para dividirlo en 4 trozos de 2.5 GB. Estos 4 trozos se escriben simultáneamente en 4 servidores de almacenamiento (OST) distintos.

La ventaja crítica del *striping* se ve durante la lectura o escritura del archivo. El rendimiento total del sistema se convierte en la suma de los anchos de banda individuales de cada servidor que contiene un trozo.

Si cada uno de los 4 servidores puede entregar datos a una velocidad de 1 GB/s, al leer el archivo en paralelo, el rendimiento efectivo total para el cliente es de 4 GB/s.

El administrador del sistema puede definir el tamaño del trozo y la cantidad de OST a utilizar para cada archivo o directorio permitiendo optimizar el rendimiento según el patrón de acceso (archivos grandes secuenciales se benefician de *striping* amplio; archivos pequeños pueden no necesitarlo).

Acceso directo (*bypass* del kernel/OS)

Los clientes del sistema de archivos paralelo hablan directamente con los discos (OSS) para leer/escribir datos, el MDS solo les dice "dónde buscar". En NFS, todo el tráfico pasa por el servidor central.

Además el tráfico NFS viaja típicamente por la red de gestión (Ethernet/Gigabit). Al usar el protocolo TCP/IP estándar, sufre de mayor latencia y comparte el ancho de banda con tareas administrativas y accesos de usuario. El tráfico del Sistema de Archivos Paralelo viaja exclusivamente por la red de baja latencia (InfiniBand / Omni-Path). Estos sistemas utilizan tecnologías como RDMA, que permiten mover datos de la memoria del servidor de discos a la memoria del nodo de cómputo sin pasar por la CPU, logrando velocidades extremas.

Regla de oro


Nunca satures la red de gestión con grandes movimientos de datos de cálculo; usá siempre el sistema paralelo para eso.

El ecosistema actual

Sistema	Tipo	Características	Uso típico
Lustre	Open Source	Muy rápido, complejo de administrar.	Supercomputadoras Top500.
GPFS (Spectrum Scale) ¹	Comercial (IBM)	Extremadamente robusto, características empresariales, caro.	Banca, Genómica, HPC corporativo.
BeeGFS	Open Source	"El Lustre fácil". Arquitectura más sencilla, gran rendimiento.	Clústeres universitarios y medianos.
CephFS	Software Defined	Basado en objetos, alta redundancia, no siempre es el más rápido para HPC puro (latencia).	Cloud, Virtualización, HPC mixto.

¹ Aunque en el mundo del HPC se le sigue llamando coloquialmente GPFS (General Parallel File System), IBM renombró oficialmente el producto como IBM Storage Scale.

En el siguiente gráfico, que ya conocimos en el módulo 1, podemos visualizar en color naranja la red de alta velocidad donde viaja el tráfico del sistema de archivos paralelo:



3.4 Recomendaciones y buenas prácticas

Estrategias de almacenamiento en HPC

¿Cómo saber cuándo usar **/home**, **/scratch** y almacenamiento local (**/tmp**)? Como administradores fundamentales del entorno de un clúster, nuestro rol trasciende la mera gestión técnica. Implica una responsabilidad crucial en la educación y la orientación de los usuarios respecto al uso óptimo y eficiente de los recursos de almacenamiento disponibles.



Es imperativo que los usuarios comprendan la distinción funcional y las políticas de retención asociadas a cada tipo de almacenamiento para garantizar el rendimiento del clúster y la integridad de sus datos. La mala praxis, como guardar archivos temporales grandes en el almacenamiento de inicio, puede degradar el rendimiento general del sistema para todos los usuarios.

A continuación, se presenta un marco para clasificar las acciones típicas de gestión de archivos según el sistema de almacenamiento más adecuado:

NFS (/home): almacenamiento persistente y de archivo

Se utiliza principalmente para el acceso de inicio de sesión y la administración del entorno:

- Datos no orientados al cómputo intensivo.
- Archivos pequeños.
- Scripts de inicio de sesión.
- Configuraciones de usuario.
- Archivos fuente (código) y directorios de construcción.
- Resultados finales, depurados y esenciales (pequeños conjuntos de datos, figuras de publicación).

No debe utilizarse para la ejecución de cargas de trabajo de E/S intensivas.

Paralelo (**/scratch**): almacenamiento temporal de alto rendimiento o *High-Performance Temporary Storage*


Este almacenamiento suele estar sujeto a políticas de purga (eliminación automática) para liberar espacio. Los usuarios deben transferir los resultados importantes a **/home** o a un almacenamiento externo al finalizar el trabajo:

- Datos orientados al cómputo intensivo.
- Archivos grandes y datos intermedios de los trabajos.
- *Checkpoints* (puntos de control) de trabajos de larga duración.
- Conjuntos de datos de entrada muy grandes.
- Salidas masivas generadas durante la ejecución de simulaciones o análisis.
- Archivos temporales.

Ejemplo de instrucción clave para usuarios:

1. Ejecutar trabajos desde **/scratch**: iniciar y escribir la salida de los trabajos de cómputo intensivo siempre debe hacerse en el almacenamiento paralelo.
2. Mantener **/home** limpio: **/home** debe reservarse solo para el código, configuraciones y los resultados finales y esenciales.
3. Monitorear **/scratch**: los usuarios deben tener un plan para mover o eliminar sus datos de **/scratch** de forma oportuna para evitar la pérdida de datos por políticas de purga y para liberar recursos.

Además a veces es conveniente tener un directorio local en cada nodo de cómputo. Si el *job* en ejecución solo necesita un nodo entonces es mejor usar una I/O local para tener una mejor performance **/tmp**. En la siguiente imagen se aprecian diferentes memorias en un mismo nodo:



En resumen:

- NFS/NAS: es ideal para **/home** (archivos pequeños, scripts, configuración). Es sencillo y barato.
- Parallel FS: es obligatorio para **/scratch** o **/work** (cálculos pesados, *datasets* gigantes). Es complejo y requiere hardware dedicado.
- Red de Datos: hay que recordar que los sistemas paralelos suelen requerir redes de alta velocidad (InfiniBand o 100GbE) para obtener su mejor rendimiento.

Advertencia crítica: actualizaciones de kernel y sistemas paralelos

A diferencia de NFS, que es nativo de Linux, los sistemas de archivos de alto rendimiento como Lustre, IBM Storage Scale (GPFS) y BeeGFS funcionan mediante módulos del kernel externos.

Existe un riesgo. Estos módulos dependen de la versión exacta del kernel en ejecución. Si aplicamos una actualización automática del sistema operativo (ej: *yum update*) que instala un nuevo kernel:

- Lustre: dejará de cargar casi con seguridad, requiriendo reinstalar un cliente compatible con esa versión específica.
- GPFS/IBM Scale: requerirá una nueva compilación de su capa de portabilidad, que podría fallar si el kernel es demasiado nuevo.

Reglas de administración HPC



- Bloquear las actualizaciones automáticas del kernel en los nodos de cómputo.
- Nunca actualizar el kernel sin antes verificar en un nodo de prueba que el cliente del sistema de archivos paralelo es compatible y compila correctamente con la nueva versión.

Control de recursos: cuotas de disco

Dado que el almacenamiento es un recurso finito y costoso, como responsables de la administración debemos implementar cuotas de disco.

Soft limit: advertencia al usuario cuando se acerca al límite. Por ejemplo: "Te queda 1GB".

Hard limit: bloqueo físico. Por ejemplo: "No podés escribir más".

Sin cuotas, un solo usuario con un código mal escrito (un bucle infinito escribiendo logs) podría llenar el disco compartido al 100% y detener el clúster para todos los demás usuarios.

Cierre



¡Felicitaciones, llegaste hasta el final del módulo 3!

Antes de pasar a los ejercicios, recomendamos que revises el [glosario del módulo](#).

En el próximo módulo nos adentraremos en la gestión de recursos y uso del clúster.



¡No pases de largo sin practicar lo aprendido!. Dirigite a la ejercitación haciendo [clic aquí](#).